Interna radionica - Vizualni transformeri i regionalna kvaliteta zraka

Marko Kvakić

Sadržaj

- Low-cost senzori i data-fusion
  - Motivacija
  - FAIRMODE WG6 benchmark
- Vizualni transformeri
  - Što su transformeri?
  - Slika kao jezik?
- Vježba
  - Opis i linkovi

Low cost senzori i data fusion

Low cost senzori i data fusion – Motivacija

Low-cost sensors

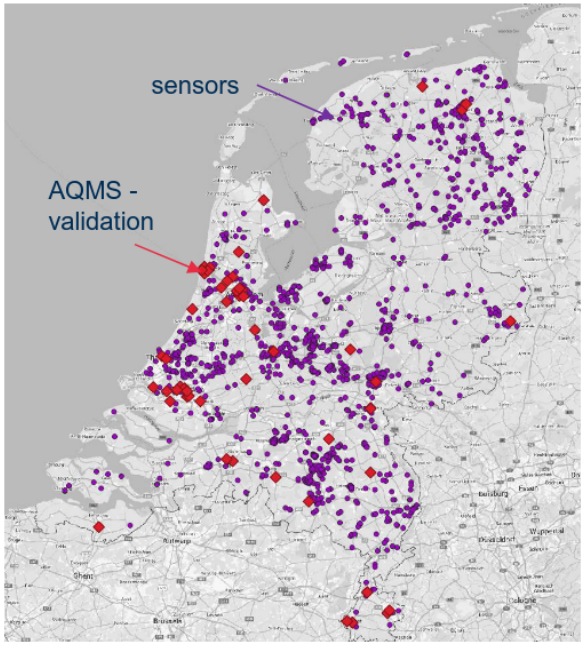

CAMS

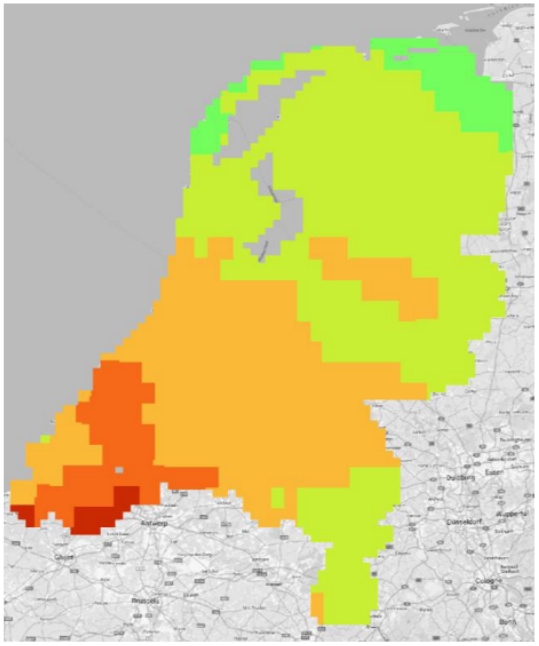

CAMS updated

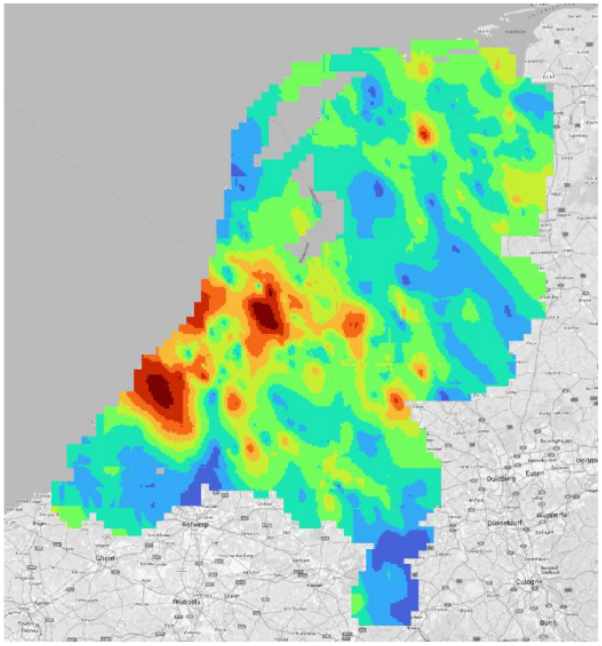

Izvor: https://knowledge4policy.ec.europa.eu/sites/default/files/5_DATA ASSIMILAITON IN THE CONTEXT OF AIR QUALITY.pdf

Low cost senzori i data fusion – FAIRMODE WG6

- FAIRMODE
  - 'EUMETNET' za modeliranje kvalitete zraka

- WG6
  - Wesseling et al. 2024
  - *„In FAIRMODE/WG6 (low-cost sensors for air quality), work is done on methods to calibrate/process the raw results of networks of low-cost sensors in such a way that the best estimates of the real/actual concentrations can be obtained"*

- $PM_{2.5}$ benchmark
  - Nizozemska tijekom 2024.
  - ~2000 low cost senzors
  - ~50 referentnih postaja

Vizualni transformeri

Vizualni transformeri – Što su transformeri?

- Što je transformer?
  - Arhitektura neuralne mreže koja je iznimno učinkovita u otkrivanju međusobnih veza niza riječi i predviđanju riječi koja slijedi
  - Nastala 2017., a popularizirana ChatGPT-om

- Ključni pojmovi
  - Tokenizacija – jezik kao niz iz rječnika
  - Embedding – zapisivanje riječi kao brojeva u 'prostoru' značenja
  - Attention (**QKV**) – mehanizam u centru transformera kojim se 'uče' međusobne veze riječi i dobija 'značenje'
  - Encoder-decoder – predviđanje budućeg teksta gledanjem unazad (decoder) i konteksta (encoder)

- Veoma topla preporuke
  - https://youtu.be/wjZofJX0v4M?si=4X1vIgJk64fyBB7c
  - https://poloclub.github.io/transformer-explainer

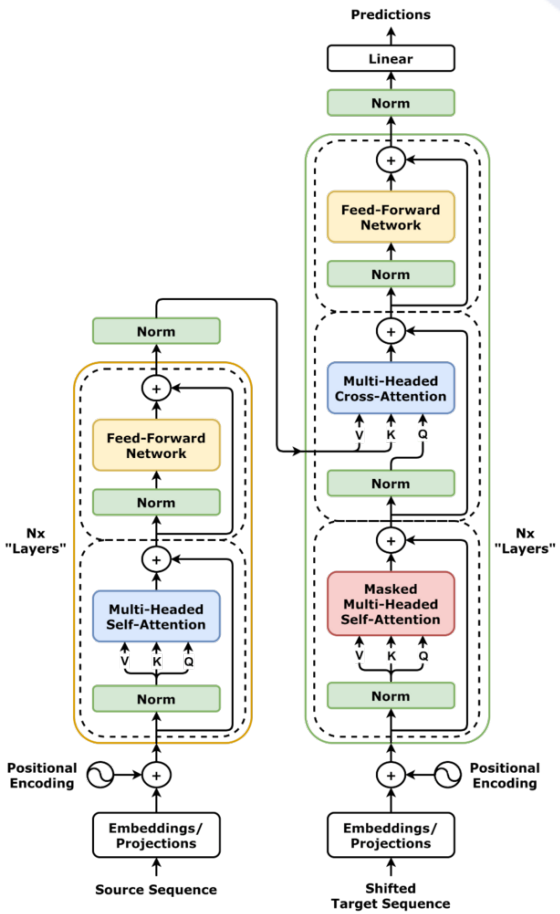

Izvor: https://en.wikipedia.org/wiki/Transformer_(deep_learning)

Vizualni transformeri – Slika kao jezik?

- Što je vizualni transformer?
  - Encoder dio transformera namijenjen klasifikaciji slika
- Kako?
  - Tokenization - dijeljenje slika u 'patcheve'
  - Embedding - stvaranje 'rječnika' vrijednosti pixela
  - Attention – slično kao i prije
  - Encoder – slika kao vjerojatnost opažanja neke kategorije/pojma

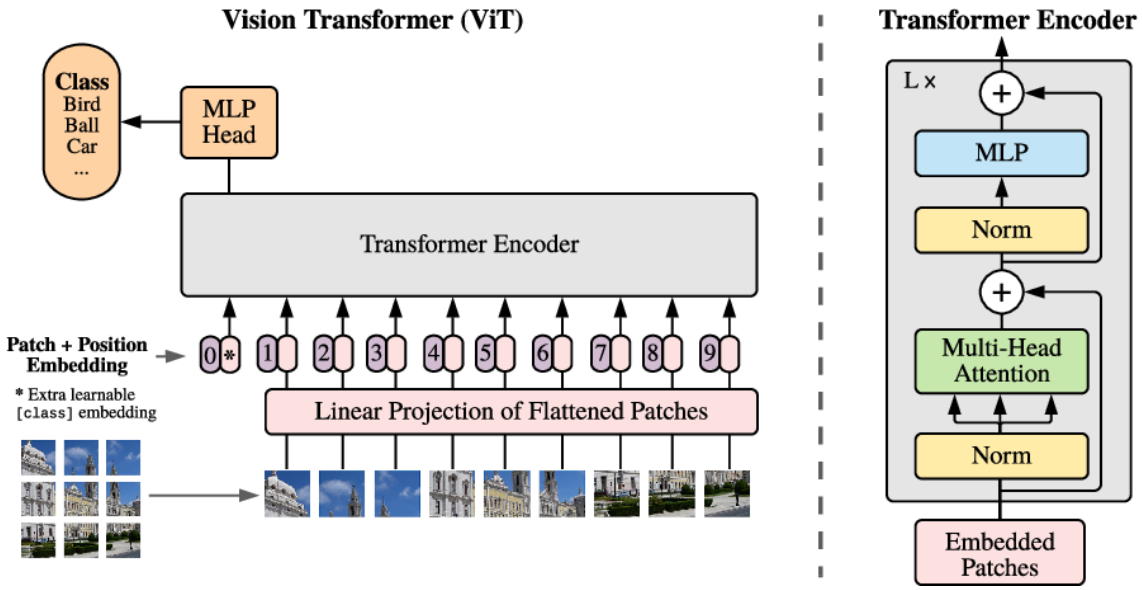

Izvor: https://en.wikipedia.org/wiki/Vision_transformer

Vježba

Vježba – Opis i linkovi

- Opis
  - Mrežu low-cost senzora pretvoriti u sliku
  - Pokušati predvidjeti opažanja na referentnim postajama u sredini

- Linkovi
  - Izvor podataka - https://samenmeten.rivm.nl/dataportaal
  - Gitlab repozitorij - https://gitlab.kras.dhz.hr/Kvakic/wg6-fusion-tutorial

- Naglasak
  - Koristiti već gotova rješenja!